Proyecto de la UT02: Análisis de datos en un clúster EMR

Una empresa digital quiere comenzar a analizar grandes volúmenes de datos procedentes de sus sistemas transaccionales utilizando tecnologías del ecosistema Hadoop. Para ello ha decidido desplegar un clúster de procesamiento distribuido en la nube que permita almacenar información en HDFS y consultarla mediante motores SQL diseñados para trabajar con grandes conjuntos de datos.

Como ingeniero o ingeniera de datos, tu tarea consiste en desplegar el clúster, explorar su funcionamiento y utilizarlo para cargar datos procedentes de una base de datos relacional. Posteriormente deberás preparar dichos datos para su análisis y realizar consultas que permitan extraer información relevante. La práctica se divide en diez apartados.

1. Creación del clúster de procesamiento

El primer paso consiste en desplegar un clúster de procesamiento distribuido en la nube utilizando el servicio EMR. Durante el proceso de creación deberás seleccionar una configuración adecuada para un entorno de laboratorio, incluyendo un nodo maestro encargado de coordinar el sistema y al menos un nodo de trabajo que participará en el procesamiento de los datos. Una vez finalizado el despliegue, espera hasta que el clúster se encuentre completamente operativo y comprueba desde la consola de administración que todos los nodos se encuentran activos.

2. Conexión al nodo maestro del clúster

Cuando el clúster esté en funcionamiento, establece una conexión remota con el nodo maestro utilizando SSH. Esta conexión te permitirá trabajar directamente en el entorno Linux del clúster. Una vez dentro, verifica que puedes ejecutar comandos básicos del sistema y examina el entorno de trabajo disponible para tu usuario, identificando los directorios principales y comprobando que el sistema responde correctamente.

3. Exploración del entorno del clúster

Una vez conectado al nodo maestro, dedica unos minutos a explorar el entorno disponible en el sistema. Observa qué herramientas del ecosistema Hadoop están instaladas y qué comandos permiten interactuar con el clúster. El objetivo de este apartado es familiarizarte con el entorno de trabajo antes de comenzar a manipular datos, identificando especialmente los comandos que permiten interactuar con el sistema de almacenamiento distribuido.

4. Acceso a las interfaces de administración

Además del acceso mediante terminal, el clúster ofrece diferentes interfaces web que permiten observar su funcionamiento interno. Accede desde el navegador a estas interfaces y examina la información que proporcionan sobre el estado del sistema, los recursos disponibles y la actividad del clúster. Analiza brevemente qué tipo de información aparece en estas interfaces y qué utilidad tienen para monitorizar un sistema de procesamiento distribuido. [***HDFS, HUE***]

5. Primer contacto con el sistema de archivos distribuido

Utilizando los comandos disponibles en el entorno Hadoop, comienza a interactuar con el sistema de archivos distribuido del clúster. En este apartado deberás crear dentro de HDFS un directorio (**input**) que servirá para almacenar datasets utilizados en tareas de análisis. Una vez creado, comprueba que el directorio aparece correctamente listado cuando consultas el contenido del sistema de archivos distribuido desde la línea de comandos.

6. Preparación del conjunto de datos

Para esta práctica, vamos a trabajar con un dataset detallado del sector turístico en las Islas Canarias que abarca registros mensuales de 2023 y principios de 2024. Tu tarea consiste en crear un archivo llamado `turismo_canarias.csv` en el directorio de tu usuario dentro del nodo maestro. Tras guardar el archivo, utiliza el comando `wc -l turismo_canarias.csv` para confirmar que el fichero tiene exactamente 51 líneas (las 50 de datos más la cabecera). Esta comprobación es un paso estándar en ingeniería de datos para asegurar que la carga de información ha sido completa.

7. Importación de datos hacia el sistema distribuido

Con el archivo local listo, debes proceder a su **ingesta** en el clúster. Utiliza el sistema de comandos de Hadoop para mover el archivo turismo_canarias.csv desde tu almacenamiento local hacia la carpeta **input** que creaste en HDFS. Una vez realizada la transferencia, verifica la ubicación del archivo en el sistema distribuido y observa sus propiedades. Al estar en HDFS, el archivo ya no depende de un solo disco físico, sino que está disponible para ser procesado en paralelo por todos los nodos de trabajo (Worker Nodes) de tu clúster EMR.

8. Creación de una base de datos analítica

Ahora estructuraremos estos datos para que sean consultables mediante SQL. Entra en el entorno de **Hive** y define una tabla externa llamada turismo_canarias. Es vital que definas correctamente las columnas: `id` (int), `isla` (string), `mes` (string), `anio` (int), `turistas` (int), `gasto_diario` (float) y `alojamiento` (string). Al configurar la tabla, indica que el formato de campo es delimitado por comas (CSV). Este paso es fundamental, ya que estás creando un "esquema en lectura", permitiendo que herramientas de análisis de alto nivel puedan interpretar los archivos planos de HDFS como si fueran tablas de una base de datos relacional.

9. Exploración de los datos mediante consultas

Con la tabla ya creada, realizarás un análisis de negocio sobre el turismo canario. Ejecuta las siguientes consultas y anota los resultados: primero, obtén la suma total de turistas que visitaron las islas en el año 2023; segundo, identifica cuál es la isla que presenta el gasto diario más alto en los meses de verano; y tercero, calcula el promedio de turistas mensuales según el tipo de alojamiento (Hotel, Apartamento o Casa Rural). Observa cómo el clúster gestiona la consulta y reflexiona sobre cómo la estructura de los datos influye en la rapidez con la que obtienes estas respuestas estadísticas.

10. Interpretación del proceso realizado

Para finalizar, redacta una conclusión sobre el flujo de trabajo realizado. Explica cómo la tecnología Big Data permite centralizar datos dispersos (como los registros mensuales de diferentes islas) en un único repositorio escalable. Comenta qué importancia tiene el nodo maestro en la coordinación de las consultas que realizaste en el punto anterior y por qué crees que empresas con millones de registros, como aerolíneas o cadenas hoteleras en Canarias, prefieren este tipo de arquitecturas distribuidas frente a las bases de datos convencionales para sus análisis de tendencia.

FORMATO DE ENTREGA

Deberás entregar toda la práctica en un único documento PDF que incluya una portada con tus datos personales, el nombre del curso y la fecha de entrega. Incorpora un índice detallado al principio del documento. Desarrolla los 10 apartados en orden, incluyendo todas las evidencias solicitadas para cada uno de ellos. Finaliza el documento con unas conclusiones generales del proyecto donde reflexiones sobre los conocimientos que has adquirido, las dificultades que has encontrado durante el desarrollo y cómo las has superado, las aplicaciones prácticas que ves para las tecnologías que has trabajado y tu valoración personal sobre el proyecto completo.

Además del PDF, entregarás una carpeta comprimida conteniendo todos los archivos generados durante la práctica si los hubiera